

Rust 编写的操作系统 MoOS

项目成员: 卢郡然、杨杰睿、唐楠青

指导老师: 夏文、仇洁婷

目录

1 概述	3
2 系统设计	4
3 模块设计	7
3.1 进程管理	7
3.1.1 概述	7
3.1.2 进程调度	8
3.1.3 进程控制块	8
3.1.4 陷阱与中断	9
3.2 内存管理	10
3.2.1 地址空间	10
3.2.2 页表	11
3.3 文件系统	12
3.3.1 概述	12
3.3.2 虚拟文件系统	14
3.3.3 磁盘文件系统	15
3.3.4 磁盘驱动	16
3.3.5 文件系统相关系统调用	16
4 测试与交互	17

1 概述

MoOS 是一个在 RISC-V 处理器架构上运行的简单内核,它主要是用 Rust 语言实现的,初赛的主要工作是为我们小组成员熟悉操作系统的架构并学习 Rust 语言提供了一个很好的基础,在编写完成操作系统基础设施的各个组件的基础上,正确的通过了初赛所有系统调用的测试用例。前期工作的代码在 GitLab 仓库的 naive-os 分支可见。

该操作系统由一系列模块化组件构成,这些组件在一起为上层应用程序提供了一个稳定可靠的运行环境。通用的操作系统的主要功能包括处理硬件中断,管理内存和任务调度,以及加载和运行用户空间的程序。我们的实现过程主要参考了rCore-Tutorial(内存部分)以及相关衍生仓库(虚拟文件系统部分)。

需要进一步指明的是,当前的 MoOS 所处的 naive-os 分支开发阶段仍处于实验阶段,尚存在大量的开发和性能提升空间,我们的前期工作将作为一个基础框架支持后续的优化和进一步竞赛要求的系统调用的实现。目前支持的系统调用如下,也即所有初赛要求的系统调用,如下图所示:

```
const SYSCALL GETCWD: usize = 17;
const SYSCALL DUP: usize = 23;
const SYSCALL_DUP3: usize = 24;
const SYSCALL_MKDIRAT: usize = 34;
const SYSCALL_UNLINKAT: usize = 35;
const SYSCALL_UMOUNT: usize = 39;
const SYSCALL_MOUNT: usize = 40;
const SYSCALL_CHDIR: usize = 49;
const SYSCALL_OPENAT: usize = 56;
const SYSCALL CLOSE: usize = 57:
const SYSCALL_PIPE2: usize = 59;
const SYSCALL_GETDENTS64: usize = 61;
const SYSCALL_READ: usize = 63;
const SYSCALL_WRITE: usize = 64;
const SYSCALL_FSTAT: usize = 80;
const SYSCALL_EXIT: usize = 93;
const SYSCALL_NANOSLEEP: usize =101;
const SYSCALL_SCHED_YIELD: usize = 124;
const SYSCALL_TIMES: usize = 153;
const SYSCALL_UNAME: usize = 160;
const SYSCALL_GETTIMEOFDAY: usize = 169;
const SYSCALL_GETPID: usize = 172;
const SYSCALL_GETPPID: usize = 173;
const SYSCALL_BRK: usize = 214;
const SYSCALL_MUNMAP: usize = 215;
const SYSCALL CLONE: usize = 220:
const SYSCALL_EXECVE: usize = 221;
const SYSCALL_MMAP: usize = 222;
const SYSCALL WAITPID: usize = 260;
```

图 1: 初赛系统调用列表

2 系统设计

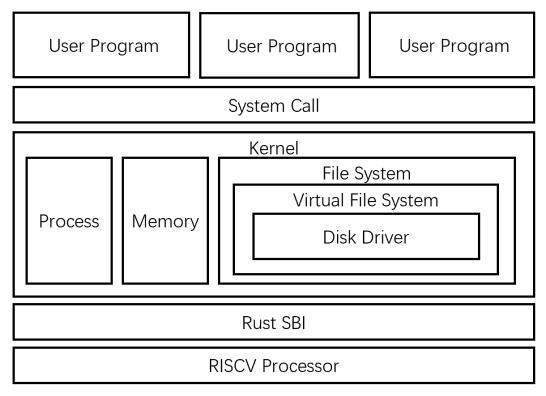


图 2: 系统架构框图

MoOS 采用了分层模块设计的思想,将操作系统的功能划分为不同的层次和模块。MoOS 的主要部分由两个层次构成:核心态和用户态。核心态是运行在Supervisor模式下的内核,它负责操作系统的核心功能,如进程管理、内存管理和文件系统。用户态是运行在User模式下的用户程序,它们通过系统调用与内核交互,实现各种应用功能。项目中提供了一个基本的用户态程序,即 shell,它可以接收用户的命令,并执行相应的操作。项目还提供了C语言标准库,使得用户可以使用C语言开发自己的用户态程序。

MoOS 的核心态内核与硬件之间通过 Rust SBI 进行通信。Rust SBI 是一个基于 Rust 语言开发的软件二进制接口(SBI),它实现了 RISC-V SBI 规范,并提供了一些扩展功能。Rust SBI 可以屏蔽硬件的差异,为上层的操作系统提供统一和安全的接口。MoOS 的核心态内核与用户态程序之间通过系统调用进行通信。MoOS 的系统调用遵循 Unix 规范,提供了一系列标准的接口,如文件操作、进程控制、信号处理等。

MoOS 的核心态内核主要由三个模块组成:进程管理、内存管理和文件系统。进

程管理模块负责创建、销毁、调度、中断、唤醒等进程相关的功能;内存管理模块负责虚拟内存和物理内存的管理;文件系统包含一个虚拟文件系统,能够通过各级抽象统一调用接口,自管理缓存实现内存与外设的高速准确交互。

具体而言,我们的操作系统内核的重要模块如下:

「TODO: 格式需要修改」

main.rs:这是操作系统的入口点。它负责初始化操作系统中的各个部分,然后 开始用户程序的执行。

config.rs:这个模块定义了一些全局常量,如用户栈大小、内核栈大小、内核 堆大小和内存末尾地址等,为内核的运行提供配置。

sbi.rs: 这个模块是 Rust SBI 的封装,通过它,MoOS 的内核能与底层硬件进行交互。Rust SBI 实现了 RISC-V SBI 规范,为操作系统与硬件之间提供了统一和安全的接口。

timer.rs: 这个模块提供了定时器相关的功能,如设置下一个定时器触发时间。

sync.rs:这个目录包含了同步原语,如原子操作和互斥体。

trap.rs:这个目录负责处理硬件陷阱,如时钟中断和系统调用。

entry.asm: 这是系统的汇编语言入口点,它设置了初始的栈指针,然后跳转到rust_main 函数。

lang_items.rs: 这个模块提供了 Rust 的一些语言项,例如 panic 处理函数。 task/:这是进程管理模块,它包含了进程控制块 (PCB),任务列表和调度算法,负责创建、销毁、调度、中断和唤醒等进程相关的功能。

mm/: 这是内存管理模块,负责虚拟内存和物理内存的管理,包括内存分配、页表管理以及地址转换。

fs/: 这是文件系统模块,它实现了一个虚拟文件系统,能够通过各级抽象统一调用接口,自管理缓存实现内存与外设的高速准确交互。

在用户态层次,我们提供了基本的用户态程序,即 shell。shell 可以接收用户的命令,并通过系统调用与内核交互,执行相应的操作。

「TODO: 格式需要修改 |

syscall.rs: 这个模块实现了 MoOS 的系统调用,遵循 Unix 规范,提供了一系列标准的接口,如文件操作、进程控制、信号处理等,它是内核与用户态程序之

间的桥梁。

此外,为了实现这些功能,MoOS 还包含了一些其他的模块:

console.rs: 这个模块负责控制台输入/输出,它提供了 print 和 println 等函数,可以在控制台上打印字符串。

boards/qemu.rs: 这个目录包含了针对 QEMU 虚拟机的硬件配置和初始化代码。

以上为对我们的操作系统的基本介绍,接下来我们将更加详细的对 MoOS 的各个模块的设计进行解析,各部分的介绍内容将包括我们当前已有的 naive-os 实现、我们正在进行的改进以及在决赛阶段我们预计实现的内容。

3 模块设计

3.1 进程管理

3.1.1 概述

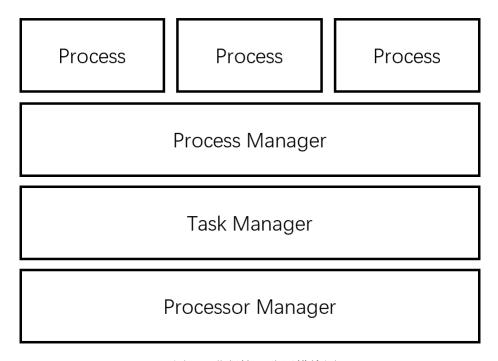


图 3: 进程管理分层模块图

进程管理是操作系统的一个重要功能,它负责对系统中的所有进程进行有效的管理和控制。为了实现这一功能,MoOS 将进程管理分为三个层次,分别是处理器管理、进程管理和进程控制。每个层次都对应了不同的抽象对象和功能模块。

处理器管理是最高层次的进程管理,它主要负责处理机或 CPU 的分配和调度。 在这一层次中,操作系统把处理机抽象为一个或多个逻辑处理器,每个逻辑处理器 可以运行一个进程。操作系统维护了一个就绪队列,用来存放等待运行的进程。同 时,操作系统还提供了一个调度器,用来根据一定的算法选择合适的进程送入处理 机运行。

进程管理是中间层次的进程管理,它主要负责对系统中存在的所有进程进行统一的管理和维护。在这一层次中,操作系统把每个进程抽象为一个 PCB (进程控制块), PCB 是用来描述和记录进程各种状态信息的数据结构。操作系统维护了一个 PCB

集合或表格,用来存放所有进程的 PCB。在这一层次并未集成大量功能,其职责是保证多核心下对于 PCB 集合或表格的互斥访问。为了实现这一点,操作系统使用了锁或信号量等同步机制。

进程控制是最低层次的进程管理,它主要负责对单个进程进行具体的控制和操作。在这一层次中,操作系统把每个 PCB 作为一个控制器,用来控制该 PCB 所代表的进程。每个控制器里集成了该 PCB 所需的全部资源和功能模块,如内存分配、文件打开、信号处理等。由于这些资源和功能模块与内存系统、文件系统等其他子系统强耦合,因此这一层次也是操作系统与其他子系统交互最频繁的地方。

3.1.2 进程调度

目前操作系统使用的轮转调度器,即按照进程标识符的顺序就近原则进行调度,被调度器选中的进程将被加载运行。这种调度方式简单有效,在有限的环境下能发挥出最大的作用。由于轮转调度器按照进程的 PID 顺序进行调度,每个进程都有机会被公平地执行。

为了保证调度过程的正确性和一致性,操作系统在进行调度时持有全局锁,也即只允许一个核心占有调度器。这种设计确保了在多核系统中不会发生冲突或竞争条件。当一个核心正在执行调度操作时,其他核心必须等待直到锁被释放。这种串行化的调度方式保证了调度过程的可靠性,防止了数据不一致或竞态条件的发生。后续会为多核系统细分持有锁的区域以提高并发。

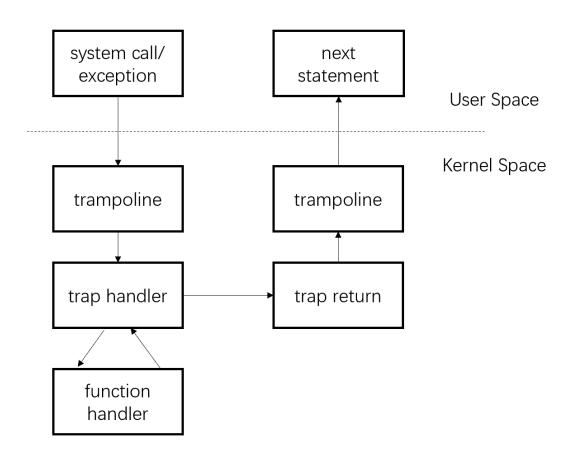
3.1.3 进程控制块

进程控制块用于管理和跟踪进程状态。其中的进程号用于唯一标识每个进程;运行状态字段跟踪进程的当前状态,如运行、就绪、阻塞等。这些信息使操作系统能够识别和管理不同的进程;进程上下文包含了进程的执行环境,包括程序计数器、寄存器状态和栈指针等。当进程被中断或切换时,操作系统可以使用进程控制块中的上下文信息保存和恢复进程的执行状态;陷阱帧的物理页号和页表字段存储了进程的内存映射信息。操作系统可以通过这些字段来管理进程的虚拟内存和物理内存之间的映射关系,以确保进程能够正确访问其所需的内存空间;堆指针字段指示了

进程的堆空间位置,使操作系统能够有效管理和分配进程的动态内存需求。父进程字段记录了进程的父子关系,方便进程间的通信和资源共享;进程控制块中的退出码字段记录了进程的终止状态,使父进程能够获取子进程的退出信息。此外,文件描述符列表存储了进程打开的文件和 I/O 设备的相关信息,用于进程间的文件共享和通信;运行时间字段记录了进程的累计运行时间,帮助操作系统进行调度决策和资源分配。工作目录字段存储了进程当前的工作目录路径,确保进程在文件系统中正确定位文件。

进程控制块提供了一个全面的视图,用于管理和控制进程的各个方面。它使我们的操作系统能够跟踪进程状态、分配和管理资源、进行进程间通信和同步,并支持调度和性能统计等。通过进程控制块,操作系统能够有效地管理多个进程的执行,确保系统的正常运行和资源利用。

3.1.4 陷阱与中断

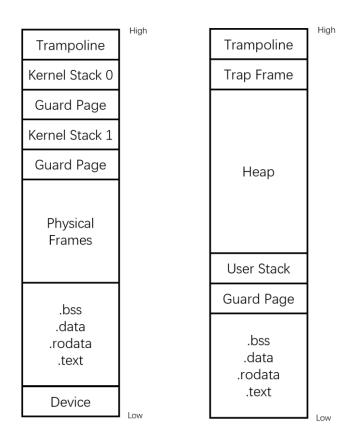


系统调用或者一些特性(如懒分配)都会触发中断,进入陷阱处理程序。在中断

陷入时由跳板程序完成对上下文、地址空间的切换,跳板程序在内核与用户地址空间被映射到同一位置以保证在切换地址空间的时候运行流程不被打断,在陷进处理程序中完成对系统调用和异常的识别和处理,以及完成一些功能(mmap、COW)。在处理中断时会关中断防止二次中断。

3.2 内存管理

3.2.1 地址空间



内存布局采用了分离的内核态和用户态页表,允许内核和用户程序拥有各自独立的地址空间,从而实现了内核和用户态的隔离。内核态页表用于映射内核代码和数据,而用户态页表则用于映射用户程序的代码和数据。

内核栈被放置在内核空间中,每个进程都在内核空间中有一个固定的位置,该 位置由进程的 PID 决定。这种方式可以确保每个进程都有自己独立的内核栈,使得

进程在内核态执行时能够正确保存和恢复其上下文。

由于内核空间与用户空间分离,为了实现内核态与用户态的数据交换,采用了 复制移动的方式。当数据需要从内核态传递到用户态或从用户态传递到内核态时, 数据会被复制到目标地址空间中,确保了数据的隔离和安全性。这种方式可以有效 地防止数据泄露或被未经授权的程序访问。

为了保证 Trap 的连贯性和处理异常的正确性,在用户空间顶部映射了 Trampoline 和 Trap Frame。Trampoline 是一个小段代码,用于实现从用户态到内 核态的转换,并将控制权传递给内核的异常处理程序。Trap Frame 则是保存了进入 异常处理程序时的 CPU 上下文的数据结构,以便异常处理程序可以正确地恢复执行 状态。在内核以及用户空间中 Trampoline 被映射到同一款区域以使得切换页表时不打断执行流程。

用户堆和页表项与内核堆一起由一个分配栈进行统一分配。这样可以有效地管理内存资源,并提供对用户堆和页表项的动态分配和释放。这种设计简化了内存管理的复杂性,提高了内存的利用效率。

3.2.2 页表

页表采用了常规的三级页表设计,这意味着虚拟地址被分成三个层次的索引: 页目录、页表和页。每个级别的索引都有自己的数据结构,用于存储与之对应的物 理页框的信息。

所有的页表项都采用相同的页大小。这种设计可以简化页表的管理和处理逻辑, 使得地址转换更加高效和一致。固定分页大小也有助于提供更好的内存管理和保护 功能,以及更好地支持虚拟内存的功能,如页面置换和页面回写等。

除了常规的页表结构,有额外的数据结构来管理已映射的内存区域。这些数据结构可以方便地进行创建、复制和销毁已映射区域的操作。它们记录了已映射内存区域的起始地址、大小和属性等信息,以便操作系统能够对内存进行更灵活的管理和操作。这些数据结构可以提高内存管理的效率,并支持内核对内存的动态分配和释放。

通过页表,操作系统实现了对虚拟内存的精细控制和管理。它能够有效地将虚拟地址转换为物理地址,并提供了内存保护、页面置换和动态内存分配等功能。这

些设计原则和数据结构的结合使得操作系统能够提供稳定、可靠且高效的内存管理功能。

3.3 文件系统

3.3.1 概述

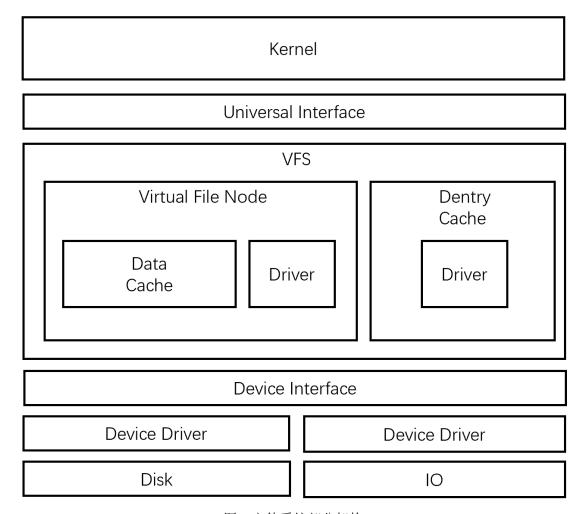


图: 文件系统部分架构

文件系统是一个与硬件强耦合且非常复杂的部分。它主要负责两方面的工作: 一是维护操作系统目录文件系统的结构和内容,二是实现操作系统与外设之间的数据交互。由于内存与外设之间存在着巨大的速度差异,为了保证高效地读写数据,这一部分需要设计大量分层缓存机制。同时,由于外设设备种类繁多且不同类型之间有很大差异,为了简化内核对外设访问的逻辑和代码量,这一部分还需要向内核提供一个统一且抽象化的接口。因此,我们将文件系统分为三个层次:接口层、文12 件节点层和数据缓存层。

接口层包含向上与内核通信的接口层,与负责负责与硬件和外设进行直接通信的硬件驱动层。它包括物理设备驱动和设备翻译两个子层。物理设备驱动是针对不同类型的物理设备(如 SD 卡、串口等)编写的程序,它可以直接控制物理设备进行读写操作。设备翻译是针对不同类型的磁盘布局(如 FAT32、EXT4 等)编写的程序,它可以将虚拟文件节点中表示数据位置和大小的信息转换为物理设备上具体扇区和字节位置。这两个子层共同构成了驱动层,它们可以屏蔽不同硬件和外设之间的差异,向上层提供一个统一且简单化的读写接口。

文件节点层,它主要负责管理管理文件节点。它将所有可能被内核访问到的字节流(如普通文件、管道、mmap 节点等)统一抽象为虚拟文件节点,并为每个虚拟文件节点提供了 open_at、read_at、write_at、close 等基本操作接口。同时,它还维护了一个完整的文件目录树结构,并为其提供了路径查找、创建、删除等操作接口。这些接口都是通过调用下层驱动层来实现具体功能的。虚拟文件系统层可以向内核提供一个统一且抽象化的访问接口,使得内核无需关心具体物理设备和磁盘布局。

每个虚拟文件节点都设置了一个独立的数据缓存区域,并根据不同类型节点采用不同策略来管理缓存内容。例如,在普通文件节点中,在内存有限的情况下采用一些置换算法来淘汰最近最少使用过的缓存块;在管道节点中,采用 FIFO 算法来按顺序传输缓存块;在 mmap 节点中,缓存写回时结合 mmap 标志位来阻止非法的写入等。数据缓存层可以利用大容量内存和局部性原理来提高数据读写速度,并减少对下层驱动层的调用次数。

在本次比赛中,由于我们有足够大的内存空间可供使用,并且所有读写需求都可以在程序开始和结束时集中处理(即挂载和卸载时),所以我们没有实现缓存换出机制,并且在挂载时就将所有需要访问到的数据全部加载进了缓存区域。这样做可以极大地提高程序运行效率,并简化缓存管理逻辑。这不完全符合实际操作系统的工作方式,但为了简化管理并且优化比赛中程序运行效率,我们暂时保留了这样的设计。

3.3.2 虚拟文件系统

虚拟文件系统是一个内核软件层,用来处理 Linux 标准文件系统相关的所有系统调用,这样一层在实际文件系统上的抽象层能为各种实际文件系统提供一个通用的接口。虚拟文件系统也是用户应用和文件系统之间操作的直接通信层,用于将用户期望进行文件系统的系统调用转换为对实际文件系统中的文件操作。

虚拟文件系统中实现了一些文件系统的通用接口,以使用通用的操作对不同的文件类型进行操作,甚至于对于一些非文件类型的内核对象(如管道等)也能以一般文件的类型来调用对应的 read_at 和 write_at 方法进行读写。在虚拟文件系统中,我们还实现了对磁盘文件系统的缓存机制,包括维护的内存文件系统结构的dcache 表(将在 mount 的时候完成初始化)。在这一部分中,我们引用了来自 rcorefs 仓库中提供的虚拟文件系统层的设计,并根据我们的实际需要进行了修改,以适配我们系统调用编写过程中的需要。

具体而言,我们构造了多个结构,实现了 Inode 相关的 trait,以进行通用的 Inode 相关的操作(如文件读写、大小获取、类型判断等)。我们实现了如 RegFileINode, TerminalINode, PipeINode 等相关结构以复用通用的 Inode 相关方法以提高开发效率。我们还实现了 Stat 结构以获取文件元数据,该结构主要用于实现 getdents 系统调用。

另外,在文件系统中还维护了如下四个全局对象:

1. 全局目录项缓存(GlobalDentryCache)

全局目录项缓存用于在内存中维护目录项结构和 inode 的对应,目录项缓存目前使用的是互斥锁哈希表维护的结构,还是存在效率问题,将会使我们在后期优化的一个重点,因为将物理文件系统中必要的数据缓存到内存中本身是为了性能提升,而加上互斥锁对频繁访问的目录项缓存会造成相对较大的性能影响,因此需要在后续进行更多的优化

2. 全局 Inode 表 (Global Inode Table)

全局 inode 表用于维护内存中的 Inode 结构,因为 FAT32 实际没有 Inode 结构,需要我们在读取之后构造正确的数据结构并保存在全局 Inode 表中。不过目前,该结构并未被很好的利用,虽然使用了 Inode 节点来管理文件元数据,但使用智能指

针直接对单个节点进行了组织,此时组织起来的列表反而没有实际作用。但我们认为,以性能为目标的我们需要考虑在决赛阶段摆脱对智能指针的依赖,因为 inode 节点的维护完全可以作为一种非内存动态管理的方式进行,而是在文件系统挂载时确定可用的内存区域作为 inode 内容的存放位置,不需要对单一的节点进行单独的智能指针管理,这样使用更大粒度的锁(整个 inode 表的大锁以减少频繁获取锁造成的性能损失。这样也是考虑到了对于文件系统的读写操作更多集中在少量的节点进行,避免对过多的 inode 互斥锁的管理造成性能障碍

3. 全局打开文件表 (GlobalOpenFileTable)

全局打开文件表用于在操作系统中记录由用户或者内核打开了的文件,并记录文件的实例指针指向实际文件的 inode。这里在目前而言是一个冗余设计,因我们在进程管理的部分实现的单个进程文件描述福表中维护的数据结构持有了一个指向文件 inode 的智能指针,所以不需要一直查到全局打开文件表才能够获取到具体 inode 的锁,但为了与通常的设计结构吻合,并且对于不恰当设计的修改留有余地,我们暂时保留了这个指针的使用,并且在未来对于全局 inode 表的修改了之后也能很方便的将指针替换为具体的 inode 标号以适配修改前后的代码

4. 全局临时缓冲区列表(GlobalBufferList)

该部分用于维护内核中需要使用的临时内核对象,因为截止目前使用到的临时内核对象只有管道的所需要使用的缓冲区,所以该部分暂时使用 GlobalBufferList 命名。而在我们的设计当中,将来的使用的其他抽象的文件(如 socket 对象)也将由同一个管理全局内核对象的结构来统一管理

3.3.3 磁盘文件系统

在虚拟文件系统的设备翻译层负责处理不同的磁盘文件系统布局与虚拟节点之间的数据交互,处理、翻译来自虚拟文件层节点的读取、写入或者查找请求,将其翻译成具体磁盘文件系统的处理动作,交由下层驱动层驱动磁盘读写。

该层也具有独立的缓存以特定数据结构组织以加速磁盘增删改查的性能。如对于要求实现的 FAT32 磁盘文件系统为若干条链组成的结构,则该层维护了空闲块列表以用于写入时加速分配、维护了若干链上索引以加速内容定位。

由于我们并不关心磁盘的内容,该层还可以实现对磁盘的 raw 格式读写,用于内存不足时的换入换出,数据以原本形式连续存放于磁盘上,达到极高的读写性能。

3.3.4 磁盘驱动

磁盘驱动的实现主要包括对底层磁盘操作的封装,例如读写磁盘块等基本操作,和对这些操作的调度和管理。在读写操作的实现中,我们引用了 qemu 提供的接口,使得我们能够通过简单的调用即可进行磁盘块的读写。这一部分我们直接参考了rCore-Tutorial 的相关实现为了进一步优化效率,我们还采用了缓存机制,将磁盘块暂存在内存中,以加快后续的读写速度。

磁盘驱动的调度和管理则主要包括请求队列的维护,请求的调度策略,以及故障的处理等。请求队列的维护主要是将上层的读写请求加入到队列中,以便统一处理;请求的调度策略则是如何从队列中选择下一个需要处理的请求,这里我们采用了最先进入队列的请求优先的策略;故障的处理则是当读写操作失败时如何进行处理,例如重新尝试读写或者报错返回。

尽管当前我们的磁盘驱动只支持 qemu,但我们在设计时尽可能考虑了通用性和扩展性,所以在之后需要支持决赛的开发板的时候,我们理论上只需实现新平台的读写接口,而无需对磁盘驱动的整体架构进行大的改动。这也是我们设计磁盘驱动时的一个重要原则,即尽可能的降低硬件平台的影响,使得我们的代码能够在不同的平台上重用。当然,这是一个理想的情况,具体的驱动编写中可能会遇到我们目前无法预料到的问题,也有待之后进一步解决

3.3.5 文件系统相关系统调用

初赛中所要求的文件系统相关系统调用共有 15 个,占据了初赛阶段所有系统调用的一半,是工作量相对繁重的部分。目前而言,我们初赛阶段的系统调用已经全部完成,并且正确的通过了所有测试点

4 测试与交互

我们在用户态实现了一个 shell 程序,可以用户简单的人机交互、调用用户态程序;一些简单的压力测试程序,以及测试用例自动化运行脚本程序,用于测例的自动运行。用户可以使用 C 语言编写用户态程序参与测试。

在 shell 模式下输入 runtest 命令或者在自动模式下直接运行会挂载磁盘并依次运行初赛测例文件。

5	202318123101332	MoOS/哈尔滨工业大学(深圳)	2023-05-19 17:09:27	28	102.0000
				_	

初赛样例能够全部通过。